

DriveWorld-VLA 论文笔记报告

1. 核心方法与创新

目标：让 VLA 决策与 World Model 未来预测统一到同一 latent space，实现“先规划→想象后果→评价→修正”。

核心闭环：

Current→Action→Future→Reward→RefineCurrent \rightarrow Action \rightarrow Future \rightarrow Reward \rightarrow Refine

三点创新：

- 1. **Shared Latent Space**：VLM 训练的隐藏层 H_t 同时服务 Action Head 和 Denoiser，实现 VLA、WM 隐形信息共享
- 2. **Action-conditioned What-if Reasoning**：从 $History \rightarrow Future$ 提升为 $History + Action \rightarrow Future$ ，显式推演“what happened if take this action”
- 3. **Three-stage Progressive Training**：先共享表示，再学习动作如何影响世界，最后用未来世界反向优化动作。

2. 重要子模块

模块	作用	输入	输出
VLM / Shared Latent	多模态信息融合	图像、BEV、历史动作、文本	潜状态 H_t
Action Head	自车轨迹预测	H_t, B_t, A_{t-1}	A'_{future}
History Denoiser	根据历史预测自然未来	H_t, B'_t, A_{t-1}	latent future BEV
Action-conditioned DiT	逐步扩散模型，推演动作造成的未来	$B'_t, A_{future}, x_k, k/N$	flow v_k ；迭代得 B'_{future}
Reward Model	评价预测动作对应未来是否安全/合理	imagined future、BEV、trajectory	reward $\hat{r}$

其中 DiT 是核心 World Model：

$$vk = DiT\theta(Bt, Afuture, xk, k/N)vk = DiT\theta(B't, Afuture, xk, k/N)$$

通过扩散模型迭代，最终得到 action-conditioned latent future BEV

3. 三阶段任务

- **Stage 1**: 共享表示 + 基础未来预测/动作预测 (stage 1的Denoiser是基础未来预测, 没有动作加入, stage2和3加入了动作), 反向误差误差定义为 $L_{s1} = L_{seg} + L_{act}$, 实现WM、VLA的耦合
- **Stage 2**: 训练 Action-conditioned DiT, 学习动作如何影响世界, 即 $p(B_{future}|B_t, A_{future})$
- **Stage 3**: $Action \rightarrow Future \rightarrow Reward$, 利用 $L'_{act} = \hat{r}|A' - A_{GT}|^2$ 修正 Action Head。

4. 实验结论

1. NAVSIM PDMS: Baseline 87.1 $\rightarrow$ Stage1 87.6 $\rightarrow$ Stage2 89.5 $\rightarrow$ Stage3 **91.3**; 说明 WM 和VLA 仅仅共享潜状态还不够, 真正缺少的是真实世界中的变化推进, **Stage2 的动作条件想象和 Stage3 的未来反馈最关键**
2. Stage2+3若直接联合训练仅 **83.6**, 渐进训练达到 **91.3**, 说明 执行动作后的世界和动作优化不能同时训练, **progressive training 是最关键设计之一**。
3. 加入 feature-level supervision 后 PDMS 从 **87.9** $\rightarrow$ **91.3**, 说明共享 latent 不能只靠最终任务监督, 需要显式特征对齐

特征监督: 利用真实未来观测经过冻结的 VLM 和 Cross-Attention 得到 GT future BEV latent $\mathcal{B}'_{t+\Delta t}$, 再通过 Flow Matching loss $\mathcal{L}_{FM}$ 监督 action-conditioned DiT, 使模型学习动作条件下的未来特征演化

$$\mathcal{H}_{t+\Delta t} = \text{VLM}_{\theta}^*(\mathcal{I}_{t+\Delta t}, \mathcal{B}_{t+\Delta t}, \mathcal{A}_{t+\Delta t}, \mathcal{T}_{t+\Delta t}), \quad (6)$$

$$\mathcal{B}'_{t+\Delta t} = \text{CROSSATTN}_{\theta}^*(\mathcal{B}_{t+\Delta t}, \mathcal{H}_{t+\Delta t}, \mathcal{H}_{t+\Delta t}). \quad (7)$$